

Plan projet — Détection de fraude à l'assurance habitation par LMM

Plan projet — ISFA 2025-2026

30 avril 2026

Table des matières

1. Cadrage affiné	1
1.1 Problématique métier	1
1.2 Hypothèse de travail	2
1.3 Périmètre	2
1.4 Valeur ajoutée pour le secteur	2
2. Stratégie données	2
3. Architecture technique	3
3.1 Pipeline d'inférence — deux scores	3
3.2 Stack technique	4
4. Planning 4 semaines	5
Semaine 1 — du 30 avril au 6 mai : Fondations & données	5
Semaine 2 — du 7 au 13 mai : Modélisation	6
Semaine 3 — du 14 au 20 mai : Application & déploiement	6

Cours : Intelligence Artificielle appliquée à l'Assurance — ML, Deep Learning & IA Générative (ISFA, 2025-2026) **Équipe** : 3 membres **Soutenance** : 15 minutes (10 min présentation + 5 min Q/R) — **cible interne** : **semaine du 25 mai 2026** **Statut sujet** : validé

1. Cadrage affiné

1.1 Problématique métier

Les assureurs habitation reçoivent chaque jour des dossiers de sinistre accompagnés de photos (dégâts des eaux, incendie, vandalisme, bris de glace). L'arrivée des modèles génératifs grand public (Stable Diffusion, Midjourney, DALL·E, Flux) abaisse drastiquement le coût de fabrication d'une fausse preuve photographique. Une fraude qui exigeait hier une mise en scène physique se résume aujourd'hui à un prompt textuel.

L'enjeu pour l'assureur est double : - **Financier** : limiter les indemnités indûment versées (la fraude représente entre 2,5 % et 10 % du coût des sinistres selon les estimations ALFA). - **Opérationnel** : ne pas allonger les délais d'instruction des dossiers légitimes ni multiplier les expertises terrain.

1.2 Hypothèse de travail

L'**axe principal** du projet est la détection des images générées par IA. La détection sur le texte de déclaration est un **complément** qui enrichit la décision et rend la démo réaliste, mais ne porte pas la valeur ajoutée scientifique du projet.

Le pipeline cible produit deux scores distincts :

1. **Score image (principal)** — Calculé par un classifieur supervisé sur des features extraites de la photo seule : embedding CLIP ViT-L/14, captions et scores VQA de BLIP-2, scores structurés de LLaVA-1.5, métadonnées EXIF. C'est ce score qui est utilisé pour mesurer la qualité scientifique du modèle (ROC-AUC, F1, recall sur la classe « image générée »).
2. **Score multimodal (enrichi)** — Combine le score image avec des features texte (handcrafted + Mistral-7B en mode *LLM-as-judge*) extraites de la déclaration de l'assuré. Permet d'arbitrer les cas frontières et apporte la dimension métier réaliste (cohérence entre ce qui est décrit et ce qui est montré).

Le système prend en entrée : - **Une photo** prétendant illustrer le sinistre (objet de l'analyse principale), - **Un texte de déclaration** décrivant le sinistre (date, lieu, circonstances, montant estimé) — optionnel.

et produit en sortie : - Un **score image** dans $[0, 1]$, - Un **score multimodal** dans $[0, 1]$ (si déclaration fournie), - Une **décision** (Légitime / À expertiser / Fraude probable) basée sur le score multimodal s'il est disponible, sinon sur le score image, - Une **explication interprétable** : heatmap GradCAM sur l'image, mise en évidence des signaux texte saillants, et tableau de contribution par feature (SHAP).

1.3 Périmètre

Dans le périmètre : - Classification binaire image : authentique vs générée par IA (axe principal). - Scoring de cohérence du texte de déclaration (axe complémentaire). - Fusion des deux signaux en un score de fraude unique. - Domaine : dégâts intérieurs habitation (dégât des eaux, incendie, bris de vitre, dégradation post-cambriolage). - Démonstrateur web Streamlit avec formulaire de déclaration complet (upload image + saisie texte structurée).

Hors périmètre : - Détection de fraude «classique» (déclaration mensongère sur une photo authentique, manipulation type Photoshop subtile sans IA générative). - Vérification d'identité, scoring de l'assuré. - Analyse multi-image / vidéo / 3D. - Production réelle (le livrable est un POC, pas un système certifié).

1.4 Valeur ajoutée pour le secteur

Le pipeline livré démontre la faisabilité d'un **filtre automatique de premier niveau** : il ne remplace pas un expert mais réduit le volume de dossiers à inspecter manuellement. La métrique cible côté métier est le **rappel sur la classe fraude** (ne rien laisser passer), avec un seuil ajustable selon l'appétit au risque de l'assureur.

2. Stratégie données

Voir le document détaillé 08_docs/strategie_dataset.md. Synthèse :

Source	Type	Volume cible	Licence
CIFAKE (HuggingFace)	Réel + synthétique génériques	60 000 paires	MIT

Source	Type	Volume cible	Licence
ArtiFact (subset)	Réel + synthétique multi-générateurs	20 000 images	CC-BY
Pexels / Unsplash / Pixabay (scraping ciblé)	Réel — dégâts habitation	1 500 images	CC0
Stable Diffusion XL Turbo (génération locale Colab)	Synthétique — dégâts habitation	1 500 images	générées par nous
Total dataset spécifique habitation (val/test)	—	~3 000	—


Approche en deux étages : 1. **Pré-entraînement / sélection de features** sur le grand dataset générique (CIFAKE + ArtiFact) pour apprendre la signature des générateurs. 2. **Évaluation et fine-tuning léger** sur le petit dataset spécifique habitation pour mesurer la capacité de transfert au domaine cible.


C’est cette articulation qui répond honnêtement au problème de la rareté des photos de sinistres réelles — point sur lequel l’enseignant interrogera presque certainement.

3. Architecture technique

3.1 Pipeline d’inférence — deux scores

L’architecture est volontairement structurée pour produire **un score image autonome** (le résultat scientifique principal du projet) auquel un **score texte** vient se greffer pour enrichir la décision finale.





Pourquoi deux classifieurs distincts ?

- Permet d'évaluer scientifiquement la performance image seule (cible principale du cours).
- Permet de chiffrer le **gain** apporté par le texte (différence de ROC-AUC entre les deux modèles), un point fort à mettre en avant en soutenance.
- Permet de servir une démo dégradée si l'assuré ne fournit pas de texte.

3.2 Stack technique

Composant	Choix retenu	Justification
Langage	Python 3.10+	Standard du domaine
Vision encoder	CLIP ViT-L/14 (OpenAI, via open_clip)	Embeddings de référence, gratuit, rapide
LMM image	BLIP-2 OPT-2.7B + LLaVA-1.5-7B en 4-bit (les deux pour comparaison et redondance)	Open-source, exécutables sur Colab T4
LLM texte	Mistral-7B-Instruct-v0.3 en 4-bit	Génération de déclarations synthétiques + LLM-as-judge sur le texte de l'assuré
Extraction entités texte	spaCy fr_core_news_md	NER (date, montant, lieu) pour features handcrafted
Génération synthétique image	diffusers + SDXL Turbo	Gratuit, rapide en local
Classifieur	scikit-learn (LogReg, RandomForest) + XGBoost	Léger, interprétable, reproductible

Composant	Choix retenu	Justification
Déséquilibre	imbalanced-learn (SMOTE, class_weight)	Standard pédagogique
Explicabilité	SHAP (sur classifieur) + GradCAM (sur CLIP) via pytorch-grad-cam	Exigence rapport
App web	Streamlit	Maîtrise existante au sein de l'équipe, écosystème mature, layout plus flexible que Gradio pour une UI métier
Hébergement	HuggingFace Spaces (free tier, runtime Streamlit)	Démo live pour la soutenance, gratuit, déploiement git-push
Versionnage	Git + GitHub	Livrable obligatoire
Notebooks	Jupyter / Google Colab	Reproductibilité

Note sur le choix Streamlit : la note de cadrage cite explicitement Streamlit / Gradio / HuggingFace Spaces comme cibles de déploiement valides. Streamlit a été retenu pour deux raisons : (1) maîtrise déjà acquise par un membre de l'équipe, ce qui réduit le risque sur la semaine 3; (2) plus de flexibilité de mise en page pour construire une UI proche d'un outil métier de gestionnaire de sinistre (sidebar, multi-pages, widgets de seuil de décision). HF Spaces supporte nativement Streamlit (runtime: streamlit dans le README.md du Space).

4. Planning 4 semaines

Aujourd'hui : **jeudi 30 avril 2026**. Soutenance cible : **lundi 25 mai 2026** (à confirmer avec l'enseignant).

Semaine 1 — du 30 avril au 6 mai : Fondations & données

Jour	Action	Responsable	Livrable
J+0 (jeu 30/04)	Création repo GitHub privé, push squelette	Membre C	Repo initialisé
J+1	Chacun installe l'environnement, fait tourner un notebook hello-world CLIP	Tous	3 envs OK
J+2	Téléchargement CIFAKE + ArtiFact (subset), EDA initiale	Membre A	02_notebooks/01_eda_datasets_gen
J+3	Scraping Pexels/Unsplash : 4 catégories (eau, feu, vitre, vandalisme)	Membre A	01_data/raw/pexels/
J+4-5	Génération SDXL : 1 500 images sur les 4 catégories	Membre B	01_data/synthetic/sd-xl/
J+6	Construction dataset final (train/val/test) avec stratification	Membre A	01_data/processed/dataset.parquet

Jour	Action	Responsable	Livrable
J+6	Point d'étape équipe (1h)	Tous	Décisions tracées

Critère sortie semaine 1 : un fichier dataset.parquet chargeable, équilibré en classes par catégorie, avec splits train/val/test stratifiés.

Semaine 2 — du 7 au 13 mai : Modélisation

Jour	Action	Responsable	Livrable
J+7	Extraction embeddings CLIP sur tout le dataset	Membre B	04_models/clip_embeddings.npy
J+8	Baseline : LogReg sur embeddings CLIP — ROC-AUC, F1, matrice de confusion	Membre B	02_notebooks/02_baseline_clip_1
J+9	Ajout XGBoost + RandomForest, comparaison	Membre B	02_notebooks/03_modeles_compar
J+10	Inférence LMM (BLIP-2) sur sous-échantillon : captions + score VQA	Membre B	02_notebooks/04_features_lmm.ip
J+11	Modèle final : embeddings CLIP + features LMM + EXIF	Membre B	04_models/final_model.pkl
J+12	SHAP + GradCAM pour interprétabilité	Membre A	02_notebooks/05_explicabilite.i
J+13	Point d'étape, gel des features	Tous	Métriques figées

Critère sortie semaine 2 : un modèle final_model.pkl avec ROC-AUC > 0.85 sur le split test du dataset générique, et > 0.70 sur le dataset spécifique habitation (cible réaliste).

Semaine 3 — du 14 au 20 mai : Application & déploiement

Jour	Action	Responsable	Livrable
J+14	Wrapper d'inférence : predict(image, texte) -> (label, score, explication)	Membre B	03_src/inference.py
J+15-16	App Streamlit : upload image + texte, affichage prédictio		