

# Plan projet — Détection de fraude à l'assurance habitation par LMM

Plan projet — ISFA 2025-2026

30 avril 2026

## Table des matières

|                                                                                                                                                                                                                                                                                                                                                                   |          |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------|
| <b>1. Cadrage affiné</b>                                                                                                                                                                                                                                                                                                                                          | <b>1</b> |
| 1.1 Problématique métier . . . . .                                                                                                                                                                                                                                                                                                                                | 2        |
| 1.2 Hypothèse de travail . . . . .                                                                                                                                                                                                                                                                                                                                | 2        |
| 1.3 Périmètre . . . . .                                                                                                                                                                                                                                                                                                                                           | 2        |
| 1.4 Valeur ajoutée pour le secteur . . . . .                                                                                                                                                                                                                                                                                                                      | 2        |
| <b>2. Stratégie données</b>                                                                                                                                                                                                                                                                                                                                       | <b>2</b> |
| <b>3. Architecture technique</b>                                                                                                                                                                                                                                                                                                                                  | <b>3</b> |
| 3.1 Pipeline d'inférence . . . . .                                                                                                                                                                                                                                                                                                                                | 3        |
| 3.2 Stack technique . . . . .                                                                                                                                                                                                                                                                                                                                     | 3        |
| <b>4. Planning 4 semaines</b>                                                                                                                                                                                                                                                                                                                                     | <b>4</b> |
| Semaine 1 — du 30 avril au 6 mai : Fondations & données . . . . .                                                                                                                                                                                                                                                                                                 | 4        |
| Semaine 2 — du 7 au 13 mai : Modélisation . . . . .                                                                                                                                                                                                                                                                                                               | 5        |
| Semaine 3 — du 14 au 20 mai : Application & déploiement . . . . .                                                                                                                                                                                                                                                                                                 | 5        |
| Semaine 4 — du 21 au 27 mai : Livrables & maintenance . . . . .                                                                                                                                                                                                                                                                                                   | 6        |
| <b>5. Répartition des rôles</b>                                                                                                                                                                                                                                                                                                                                   | <b>6</b> |
| <b>6. Métriques de succès</b>                                                                                                                                                                                                                                                                                                                                     | <b>7</b> |
| 6.1 Performance modèle . . . . .                                                                                                                                                                                                                                                                                                                                  | 7        |
| 6.2 Livrables (consignes ISFA) . . . . .                                                                                                                                                                                                                                                                                                                          | 7        |
| <b>7. Risques et mitigations</b>                                                                                                                                                                                                                                                                                                                                  | <b>7</b> |
| <b>8. Bibliographie de démarrage (à étoffer)</b>                                                                                                                                                                                                                                                                                                                  | <b>8</b> |
| <b>9. Point d'attention maintenance</b>                                                                                                                                                                                                                                                                                                                           | <b>9</b> |
| <b>Cours</b> : Intelligence Artificielle appliquée à l'Assurance — ML, Deep Learning & IA Générative (ISFA, 2025-2026) <b>Encadrant</b> : Aurélien Couloumy (acouloumy@dylogy.com) <b>Équipe</b> : 3 membres <b>Soutenance</b> : 15 minutes (10 min présentation + 5 min Q/R) — <b>cible interne</b> : <b>semaine du 25 mai 2026</b> <b>Statut sujet</b> : validé |          |

## 1. Cadrage affiné

## 1.1 Problématique métier

Les assureurs habitation reçoivent chaque jour des dossiers de sinistre accompagnés de photos (dégâts des eaux, incendie, vandalisme, bris de glace). L'arrivée des modèles génératifs grand public (Stable Diffusion, Midjourney, DALL·E, Flux) abaisse drastiquement le coût de fabrication d'une fausse preuve photographique. Une fraude qui exigeait hier une mise en scène physique se résume aujourd'hui à un prompt textuel.

L'enjeu pour l'assureur est double : - **Financier** : limiter les indemnisations indûment versées (la fraude représente entre 2,5 % et 10 % du coût des sinistres selon les estimations ALFA). - **Opérationnel** : ne pas allonger les délais d'instruction des dossiers légitimes ni multiplier les expertises terrain.

## 1.2 Hypothèse de travail

Un pipeline combinant un **encodeur visuel pré-entraîné** (CLIP), un **LMM open-source** pour l'analyse sémantique de scène, et un **classifieur supervisé léger** entraîné sur les embeddings, permet de discriminer une photo authentique d'une photo générée par IA avec une performance suffisante pour être déployable en première ligne de tri (avant escalade humaine).

## 1.3 Périmètre

**Dans le périmètre** : - Classification binaire image-niveau : authentique vs générée par IA. - Domaine : dégâts intérieurs habitation (dégât des eaux, incendie, bris de vitre, dégradation post-cambriolage). - Démonstrateur web fonctionnel (upload image + texte de déclaration).

**Hors périmètre** : - Détection de fraude « classique » (déclaration mensongère sur une photo authentique, manipulation type Photoshop subtile sans IA générative). - Vérification d'identité, scoring de l'assuré. - Analyse multi-image / vidéo / 3D. - Production réelle (le livrable est un POC, pas un système certifié).

## 1.4 Valeur ajoutée pour le secteur

Le pipeline livré démontre la faisabilité d'un **filtre automatique de premier niveau** : il ne remplace pas un expert mais réduit le volume de dossiers à inspecter manuellement. La métrique cible côté métier est le **rappel sur la classe fraude** (ne rien laisser passer), avec un seuil ajustable selon l'appétit au risque de l'assureur.

## 2. Stratégie données

Voir le document détaillé 08\_docs/strategie\_dataset.md. Synthèse :

| Source                                                    | Type                                    | Volume cible  | Licence           |
|-----------------------------------------------------------|-----------------------------------------|---------------|-------------------|
| CIFAKE<br>(HuggingFace)                                   | Réel + synthétique<br>génériques        | 60 000 paires | MIT               |
| ArtiFact (subset)                                         | Réel + synthétique<br>multi-générateurs | 20 000 images | CC-BY             |
| Pexels / Unsplash /<br>Pixabay (scraping<br>ciblé)        | Réel — dégâts<br>habitation             | 1 500 images  | CC0               |
| Stable Diffusion XL<br>Turbo (génération<br>locale Colab) | Synthétique —<br>dégâts habitation      | 1 500 images  | générées par nous |

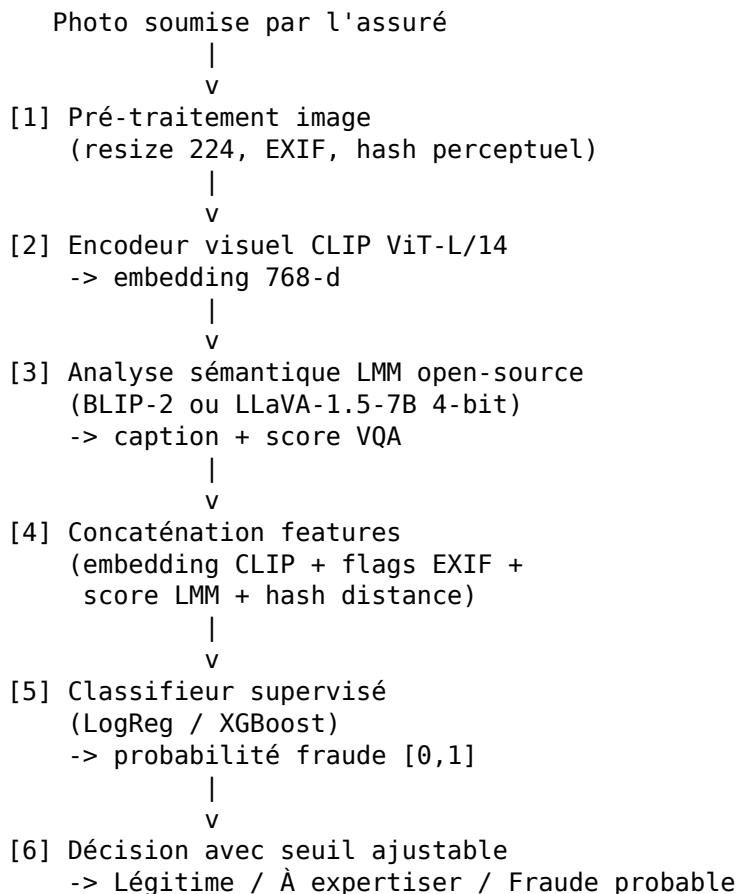
| Source                                               | Type | Volume cible | Licence |
|------------------------------------------------------|------|--------------|---------|
| Total dataset<br>spécifique habitation<br>(val/test) | —    | ~3 000       | —       |

**Approche en deux étapes** : 1. **Pré-entraînement / sélection de features** sur le grand dataset générique (CIFAKE + ArtiFact) pour apprendre la signature des générateurs. 2. **Évaluation et fine-tuning léger** sur le petit dataset spécifique habitation pour mesurer la capacité de transfert au domaine cible.

C'est cette articulation qui répond honnêtement au problème de la rareté des photos de sinistres réelles — point sur lequel l'enseignant interrogera presque certainement.

## 3. Architecture technique

### 3.1 Pipeline d'inférence



### 3.2 Stack technique

| Composant | Choix retenu | Justification       |
|-----------|--------------|---------------------|
| Langage   | Python 3.10+ | Standard du domaine |

| Composant              | Choix retenu                                                                  | Justification                                                                                                 |
|------------------------|-------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------|
| Vision encoder         | CLIP ViT-L/14 (OpenAI, via <code>open_clip</code> )                           | Embeddings de référence, gratuit, rapide                                                                      |
| LMM                    | BLIP-2 OPT-2.7B (baseline) puis LLaVA-1.5-7B en 4-bit (cible)                 | Open-source, exécutables sur Colab T4                                                                         |
| Génération synthétique | diffusers + SDXL Turbo                                                        | Gratuit, rapide en local                                                                                      |
| Classifieur            | scikit-learn (LogReg, RandomForest) + XGBoost                                 | Léger, interprétable, reproductible                                                                           |
| Déséquilibre           | imbalanced-learn (SMOTE, <code>class_weight</code> )                          | Standard pédagogique                                                                                          |
| Explicabilité          | SHAP (sur classifieur) + GradCAM (sur CLIP) via <code>pytorch-grad-cam</code> | Exigence rapport                                                                                              |
| App web                | Streamlit                                                                     | Maîtrise existante au sein de l'équipe, écosystème mature, layout plus flexible que Gradio pour une UI métier |
| Hébergement            | HuggingFace Spaces (free tier, runtime Streamlit)                             | Démo live pour la soutenance, gratuit, déploiement git-push                                                   |
| Versionnage            | Git + GitHub                                                                  | Livrable obligatoire                                                                                          |
| Notebooks              | Jupyter / Google Colab                                                        | Reproductibilité                                                                                              |

**Note sur le choix Streamlit** : la note de cadrage cite explicitement Streamlit / Gradio / HuggingFace Spaces comme cibles de déploiement valides. Streamlit a été retenu pour deux raisons : (1) maîtrise déjà acquise par un membre de l'équipe, ce qui réduit le risque sur la semaine 3 ; (2) plus de flexibilité de mise en page pour construire une UI proche d'un outil métier de gestionnaire de sinistre (sidebar, multi-pages, widgets de seuil de décision). HF Spaces supporte nativement Streamlit (runtime: `streamlit` dans le README.md du Space).

## 4. Planning 4 semaines

Aujourd'hui : **jeudi 30 avril 2026**. Soutenance cible : **lundi 25 mai 2026** (à confirmer avec l'enseignant).

### Semaine 1 — du 30 avril au 6 mai : Fondations & données

| Jour            | Action                                                                     | Responsable | Livrable                         |
|-----------------|----------------------------------------------------------------------------|-------------|----------------------------------|
| J+0 (jeu 30/04) | Création repo GitHub privé, push squelette                                 | Membre C    | Repo initialisé                  |
| J+1             | Chacun installe l'environnement, fait tourner un notebook hello-world CLIP | Tous        | 3 envs OK                        |
| J+2             | Téléchargement CIFAKE + ArtiFact (subset), EDA initiale                    | Membre A    | 02_notebooks/01_eda_datasets_gen |

| Jour  | Action                                                                         | Responsable | Livrable                          |
|-------|--------------------------------------------------------------------------------|-------------|-----------------------------------|
| J+3   | Scraping<br>Pexels/Unsplash : 4<br>catégories (eau, feu,<br>vitre, vandalisme) | Membre A    | 01_data/raw/pexels/               |
| J+4-5 | Génération SDXL : 1<br>500 images sur les 4<br>catégories                      | Membre B    | 01_data/synthetic/sd-xl/          |
| J+6   | Construction dataset<br>final (train/val/test)<br>avec stratification          | Membre A    | 01_data/processed/dataset.parquet |
| J+6   | Point d'étape équipe<br>(1h)                                                   | Tous        | Décisions tracées                 |

**Critère sortie semaine 1** : un fichier dataset.parquet chargeable, équilibré en classes par catégorie, avec splits train/val/test stratifiés.

## Semaine 2 — du 7 au 13 mai : Modélisation

| Jour | Action                                                                             | Responsable | Livrable                         |
|------|------------------------------------------------------------------------------------|-------------|----------------------------------|
| J+7  | Extraction<br>embeddings CLIP sur<br>tout le dataset                               | Membre B    | 04_models/clip_embeddings.npy    |
| J+8  | Baseline : LogReg<br>sur embeddings CLIP<br>— ROC-AUC, F1,<br>matrice de confusion | Membre B    | 02_notebooks/02_baseline_clip_1  |
| J+9  | Ajout XGBoost +<br>RandomForest,<br>comparaison                                    | Membre B    | 02_notebooks/03_modeles_compar   |
| J+10 | Inférence LMM<br>(BLIP-2) sur<br>sous-échantillon :<br>captions + score VQA        | Membre B    | 02_notebooks/04_features_lmm.ip  |
| J+11 | Modèle final :<br>embeddings CLIP +<br>features LMM +<br>EXIF                      | Membre B    | 04_models/final_model.pkl        |
| J+12 | SHAP + GradCAM<br>pour interprétabilité                                            | Membre A    | 02_notebooks/05_explicabilite.ip |
| J+13 | Point d'étape, gel des<br>features                                                 | Tous        | Métriques figées                 |

**Critère sortie semaine 2** : un modèle final\_model.pkl avec ROC-AUC > 0.85 sur le split test du dataset générique, et > 0.70 sur le dataset spécifique habitation (cible réaliste).

## Semaine 3 — du 14 au 20 mai : Application & déploiement

| Jour    | Action                                                                                                       | Responsable | Livrable                          |
|---------|--------------------------------------------------------------------------------------------------------------|-------------|-----------------------------------|
| J+14    | Wrapper d'inférence :<br>predict(image, texte) -> (label, score, explication)                                | Membre B    | 03_src/inference.py               |
| J+15-16 | App Streamlit :<br>upload image + texte, affichage prédiction + heatmap GradCAM, slider de seuil de décision | Membre C    | 05_app/app.py                     |
| J+17    | Déploiement<br>HuggingFace Spaces (runtime Streamlit), test bout-en-bout                                     | Membre C    | URL Space publique                |
| J+18    | Analyse de sensibilité : variation seuil, robustesse au bruit, cas adverses                                  | Membre A    | 02_notebooks/06_sensibilite.ipynb |
| J+19    | Génération des figures finales pour le rapport (matrices, courbes ROC, exemples)                             | Membre A    | 06_reports/figures/               |
| J+20    | Point d'étape, gel des résultats                                                                             | Tous        | Tous chiffres figés               |

**Critère sortie semaine 3** : démo Gradio publique sur HF Spaces, traitant une image en moins de 10 secondes.

## Semaine 4 — du 21 au 27 mai : Livrables & soutenance

| Jour    | Action                                                | Responsable            | Livrable                        |
|---------|-------------------------------------------------------|------------------------|---------------------------------|
| J+21-22 | Rédaction rapport (10-15 pages PDF, plan ISFA imposé) | Membre C (lead) + tous | 06_reports/rapport_final.pdf    |
| J+23-24 | Construction PPT (10-12 slides max, visuel)           | Membre A (lead) + tous | 07_presentation/soutenance.pptx |
| J+25    | Répétition orale 1 (10 min chrono, chacun parle)      | Tous                   | Notes corrections               |
| J+26    | Répétition orale 2 + scénario démo live               | Tous                   | Démo sécurisée                  |
| J+27    | Buffer / corrections / soutenance                     | Tous                   | —                               |

## 5. Répartition des rôles

L'enseignant peut interroger chaque membre sur n'importe quelle partie : **chacun doit comprendre l'ensemble**. La répartition ci-dessous est une responsabilité de pilotage, pas

un cloisonnement.

| Membre                           | Pilotage principal                                           | Doit aussi savoir expliquer          |
|----------------------------------|--------------------------------------------------------------|--------------------------------------|
| <b>A — Data &amp; analyse</b>    | Acquisition, nettoyage, EDA, stratification, sensibilité     | Architecture du modèle, choix du LMM |
| <b>B — Modélisation</b>          | Extraction features, entraînement, évaluation, explicabilité | Provenance et biais du dataset       |
| <b>C — MLOps &amp; livrables</b> | Squelette repo, app Gradio, déploiement HF, rapport, PPT     | Justification métier et limites      |

## 6. Métriques de succès

### 6.1 Performance modèle

| Métrique                    | Cible générique (CIFAKE+ArtiFact) | Cible domaine (habitation) | Justification                              |
|-----------------------------|-----------------------------------|----------------------------|--------------------------------------------|
| ROC-AUC                     | > 0.90                            | > 0.75                     | Synthèse standard, robuste au déséquilibre |
| F1 (classe fraude)          | > 0.85                            | > 0.70                     | Compromis precision/recall                 |
| Recall (classe fraude)      | > 0.85                            | > 0.80                     | Métrique métier prioritaire                |
| Latence inférence (1 image) | < 10 s sur HF Spaces (Streamlit)  | —                          | Convient à un usage opérationnel           |

### 6.2 Livrables (consignes ISFA)

- Rapport PDF 10-15 pages (plan imposé en 7 sections).
- PPT synthétique 10-12 slides.
- Notebook Jupyter exécutable + repo GitHub public ou partagé.
- Application déployée fonctionnelle (Gradio sur HF Spaces).

## 7. Risques et mitigations

| #  | Risque                                             | Probabilité | Impact | Mitigation                                                                                        |
|----|----------------------------------------------------|-------------|--------|---------------------------------------------------------------------------------------------------|
| R1 | Dataset spécifique habitation trop petit ou biaisé | Élevée      | Élevé  | Étage 1 sur dataset générique pour pré-train + acceptation explicite de la limite dans le rapport |

| #  | Risque                                                                              | Probabilité | Impact | Mitigation                                                                                                         |
|----|-------------------------------------------------------------------------------------|-------------|--------|--------------------------------------------------------------------------------------------------------------------|
| R2 | LLaVA / BLIP-2 trop lourd pour Colab Free                                           | Moyenne     | Moyen  | Quantization 4-bit, batch size 1, fallback CLIP-seul si nécessaire                                                 |
| R3 | HuggingFace Space tombe en panne le jour J                                          | Faible      | Élevé  | Démo locale streamlit run 05_app/app.py en backup + capture vidéo de la démo                                       |
| R4 | Sur-apprentissage sur la signature SDXL (le modèle n'apprend que « SDXL vs photo ») | Élevée      | Moyen  | Évaluation cross-générateur (Midjourney, Flux) pour mesurer la généralisation                                      |
| R5 | Indisponibilité d'un membre (maladie, charge pro)                                   | Moyenne     | Moyen  | Documentation systématique en cellules markdown, code commenté, aucune dépendance personne-machine locale critique |
| R6 | Manque de temps pour la soutenance                                                  | Moyenne     | Élevé  | Buffer de 2 jours en S4, répétitions chronométrées en S4                                                           |

## 8. Bibliographie de démarrage (à étoffer)

- Bird, J. J., & Lotfi, A. (2024). *CIFAKE : Image Classification and Explainable Identification of AI-Generated Synthetic Images*. IEEE Access.
- Rahman, M. A., et al. (2023). *ArtiFact : A Large-Scale Dataset with Artificial and Factual Images for Generalizable and Robust Synthetic Image Detection*. ICIP.
- Radford, A., et al. (2021). *Learning Transferable Visual Models From Natural Language Supervision* (CLIP). ICML.
- Liu, H., et al. (2023). *Visual Instruction Tuning* (LLaVA). NeurIPS.
- Li, J., et al. (2023). *BLIP-2 : Bootstrapping Language-Image Pre-training* (BLIP-2). ICML.
- ALFA — Agence pour la Lutte contre la Fraude à l'Assurance, rapports annuels.
- ACPR — recommandations sur l'usage de l'IA dans le secteur financier.



## 9. Point d'attention soutenance

Sur 20 points, **8 points sont alloués à la présentation orale** (dont la qualité des réponses aux questions). Conséquences pratiques :

- Construire le PPT autour d'**une seule histoire** : «voici le problème métier, voici notre approche, voici la démo, voici les limites assumées».
- La **démo live** est explicitement encouragée par la note de cadrage. Elle doit être courte (90 secondes max) et tester un cas lé