

Plan projet — Détection de fraude à l'assurance habitation par LMM

Plan projet — ISFA 2025-2026

30 avril 2026

Table des matières

1. Cadrage affiné	1
1.1 Problématique métier	2
1.2 Hypothèse de travail	2
1.3 Périmètre	2
1.4 Valeur ajoutée pour le secteur	2
2. Stratégie données	2
3. Architecture technique	3
3.1 Pipeline d'inférence	3
3.2 Stack technique	3
4. Planning 4 semaines	4
Semaine 1 — du 30 avril au 6 mai : Fondations & données	4
Semaine 2 — du 7 au 13 mai : Modélisation	5
Semaine 3 — du 14 au 20 mai : Application & déploiement	5
Semaine 4 — du 21 au 27 mai : Livrables & soutenance	6
5. Répartition des rôles	6
6. Métriques de succès	7
6.1 Performance modèle	7
6.2 Livrables (consignes ISFA)	7
7. Risques et mitigations	7
8. Bibliographie de démarrage (à étoffer)	8
9. Point d'attention soutenance	9
Cours : Intelligence Artificielle appliquée à l'Assurance — ML, Deep Learning & IA Générative (ISFA, 2025-2026) Encadrant : Antoine Couloumy (acouloumy@dylogy.com) Équipe : 3 membres Soutenance : 15 minutes (10 min présentation + 5 min Q/R) — cible interne : semaine du 25 mai 2026 Statut sujet : validé	

1. Cadrage affiné

1.1 Problématique métier

Les assureurs habitation reçoivent chaque jour des dossiers de sinistre accompagnés de photos (dégâts des eaux, incendie, vandalisme, bris de glace). L'arrivée des modèles génératifs grand public (Stable Diffusion, Midjourney, DALL·E, Flux) abaisse drastiquement le coût de fabrication d'une fausse preuve photographique. Une fraude qui exigeait hier une mise en scène physique se résume aujourd'hui à un prompt textuel.

L'enjeu pour l'assureur est double : - **Financier** : limiter les indemnisations indûment versées (la fraude représente entre 2,5 % et 10 % du coût des sinistres selon les estimations ALFA). - **Opérationnel** : ne pas allonger les délais d'instruction des dossiers légitimes ni multiplier les expertises terrain.

1.2 Hypothèse de travail

Un pipeline combinant un **encodeur visuel pré-entraîné** (CLIP), un **LMM open-source** pour l'analyse sémantique de scène, et un **classifieur supervisé léger** entraîné sur les embeddings, permet de discriminer une photo authentique d'une photo générée par IA avec une performance suffisante pour être déployable en première ligne de tri (avant escalade humaine).

1.3 Périmètre

Dans le périmètre : - Classification binaire image-niveau : authentique vs générée par IA. - Domaine : dégâts intérieurs habitation (dégât des eaux, incendie, bris de vitre, dégradation post-cambriolage). - Démonstrateur web fonctionnel (upload image + texte de déclaration).

Hors périmètre : - Détection de fraude « classique » (déclaration mensongère sur une photo authentique, manipulation type Photoshop subtile sans IA générative). - Vérification d'identité, scoring de l'assuré. - Analyse multi-image / vidéo / 3D. - Production réelle (le livrable est un POC, pas un système certifié).

1.4 Valeur ajoutée pour le secteur

Le pipeline livré démontre la faisabilité d'un **filtre automatique de premier niveau** : il ne remplace pas un expert mais réduit le volume de dossiers à inspecter manuellement. La métrique cible côté métier est le **rappel sur la classe fraude** (ne rien laisser passer), avec un seuil ajustable selon l'appétit au risque de l'assureur.

2. Stratégie données

Voir le document détaillé 08_docs/strategie_dataset.md. Synthèse :

Source	Type	Volume cible	Licence
CIFAKE (HuggingFace)	Réel + synthétique génériques	60 000 paires	MIT
ArtiFact (subset)	Réel + synthétique multi-générateurs	20 000 images	CC-BY
Pexels / Unsplash / Pixabay (scraping ciblé)	Réel — dégâts habitation	1 500 images	CC0
Stable Diffusion XL Turbo (génération locale Colab)	Synthétique — dégâts habitation	1 500 images	générées par nous

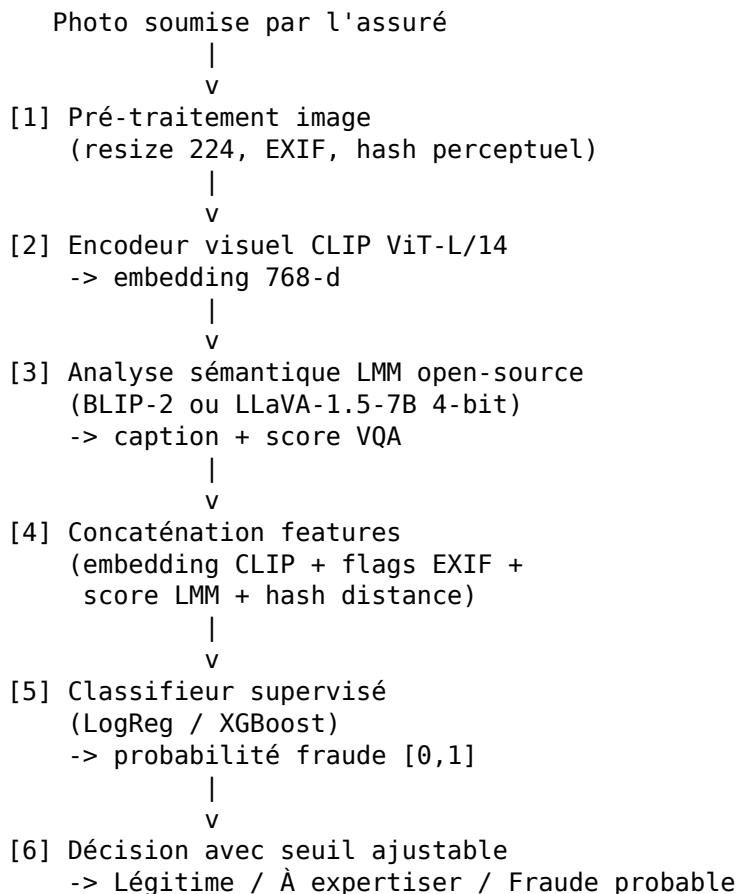
Source	Type	Volume cible	Licence
Total dataset spécifique habitation (val/test)	—	~3 000	—

Approche en deux étages : 1. **Pré-entraînement / sélection de features** sur le grand dataset générique (CIFAKE + ArtiFact) pour apprendre la signature des générateurs. 2. **Évaluation et fine-tuning léger** sur le petit dataset spécifique habitation pour mesurer la capacité de transfert au domaine cible.

C'est cette articulation qui répond honnêtement au problème de la rareté des photos de sinistres réelles — point sur lequel l'enseignant interrogera presque certainement.

3. Architecture technique

3.1 Pipeline d'inférence



3.2 Stack technique

Composant	Choix retenu	Justification
Langage	Python 3.10+	Standard du domaine

Composant	Choix retenu	Justification
Vision encoder	CLIP ViT-L/14 (OpenAI, via <code>open_clip</code>)	Embeddings de référence, gratuit, rapide
LMM	BLIP-2 OPT-2.7B (baseline) puis LLaVA-1.5-7B en 4-bit (cible)	Open-source, exécutables sur Colab T4
Génération synthétique	diffusers + SDXL Turbo	Gratuit, rapide en local
Classifieur	scikit-learn (LogReg, RandomForest) + XGBoost	Léger, interprétable, reproductible
Déséquilibre	imbalanced-learn (SMOTE, <code>class_weight</code>)	Standard pédagogique
Explicabilité	SHAP (sur classifieur) + GradCAM (sur CLIP) via <code>pytorch-grad-cam</code>	Exigence rapport
App web	Streamlit	Maîtrise existante au sein de l'équipe, écosystème mature, layout plus flexible que Gradio pour une UI métier
Hébergement	HuggingFace Spaces (free tier, runtime Streamlit)	Démo live pour la soutenance, gratuit, déploiement git-push
Versionnage	Git + GitHub	Livrable obligatoire
Notebooks	Jupyter / Google Colab	Reproductibilité

Note sur le choix Streamlit : la note de cadrage cite explicitement Streamlit / Gradio / HuggingFace Spaces comme cibles de déploiement valides. Streamlit a été retenu pour deux raisons : (1) maîtrise déjà acquise par un membre de l'équipe, ce qui réduit le risque sur la semaine 3 ; (2) plus de flexibilité de mise en page pour construire une UI proche d'un outil métier de gestionnaire de sinistre (sidebar, multi-pages, widgets de seuil de décision). HF Spaces supporte nativement Streamlit (runtime: `streamlit` dans le README.md du Space).

4. Planning 4 semaines

Aujourd'hui : **jeudi 30 avril 2026**. Soutenance cible : **lundi 25 mai 2026** (à confirmer avec l'enseignant).

Semaine 1 — du 30 avril au 6 mai : Fondations & données

Jour	Action	Responsable	Livrable
J+0 (jeu 30/04)	Création repo GitHub privé, push squelette	Membre C	Repo initialisé
J+1	Chacun installe l'environnement, fait tourner un notebook hello-world CLIP	Tous	3 envs OK
J+2	Téléchargement CIFAKE + ArtiFact (subset), EDA initiale	Membre A	02_notebooks/01_eda_datasets_gen

Jour	Action	Responsable	Livrable
J+3	Scraping Pexels/Unsplash : 4 catégories (eau, feu, vitre, vandalisme)	Membre A	01_data/raw/pexels/
J+4-5	Génération SDXL : 1 500 images sur les 4 catégories	Membre B	01_data/synthetic/sd-xl/
J+6	Construction dataset final (train/val/test) avec stratification	Membre A	01_data/processed/dataset.parquet
J+6	Point d'étape équipe (1h)	Tous	Décisions tracées

Critère sortie semaine 1 : un fichier dataset.parquet chargeable, équilibré en classes par catégorie, avec splits train/val/test stratifiés.

Semaine 2 — du 7 au 13 mai : Modélisation

Jour	Action	Responsable	Livrable
J+7	Extraction embeddings CLIP sur tout le dataset	Membre B	04_models/clip_embeddings.npy
J+8	Baseline : LogReg sur embeddings CLIP — ROC-AUC, F1, matrice de confusion	Membre B	02_notebooks/02_baseline_clip_1
J+9	Ajout XGBoost + RandomForest, comparaison	Membre B	02_notebooks/03_modeles_compar
J+10	Inférence LMM (BLIP-2) sur sous-échantillon : captions + score VQA	Membre B	02_notebooks/04_features_lmm.ip
J+11	Modèle final : embeddings CLIP + features LMM + EXIF	Membre B	04_models/final_model.pkl
J+12	SHAP + GradCAM pour interprétabilité	Membre A	02_notebooks/05_explicabilite.ip
J+13	Point d'étape, gel des features	Tous	Métriques figées

Critère sortie semaine 2 : un modèle final_model.pkl avec ROC-AUC > 0.85 sur le split test du dataset générique, et > 0.70 sur le dataset spécifique habitation (cible réaliste).

Semaine 3 — du 14 au 20 mai : Application & déploiement

Jour	Action	Responsable	Livrable
J+14	Wrapper d'inférence : predict(image, texte) -> (label, score, explication)	Membre B	03_src/inference.py
J+15-16	App Streamlit : upload image + texte, affichage prédiction + heatmap GradCAM, slider de seuil de décision	Membre C	05_app/app.py
J+17	Déploiement HuggingFace Spaces (runtime Streamlit), test bout-en-bout	Membre C	URL Space publique
J+18	Analyse de sensibilité : variation seuil, robustesse au bruit, cas adverses	Membre A	02_notebooks/06_sensibilite.ipynb
J+19	Génération des figures finales pour le rapport (matrices, courbes ROC, exemples)	Membre A	06_reports/figures/
J+20	Point d'étape, gel des résultats	Tous	Tous chiffres figés

Critère sortie semaine 3 : démo Gradio publique sur HF Spaces, traitant une image en moins de 10 secondes.

Semaine 4 — du 21 au 27 mai : Livrables & soutenance

Jour	Action	Responsable	Livrable
J+21-22	Rédaction rapport (10-15 pages PDF, plan ISFA imposé)	Membre C (lead) + tous	06_reports/rapport_final.pdf
J+23-24	Construction PPT (10-12 slides max, visuel)	Membre A (lead) + tous	07_presentation/soutenance.pptx
J+25	Répétition orale 1 (10 min chrono, chacun parle)	Tous	Notes corrections
J+26	Répétition orale 2 + scénario démo live	Tous	Démo sécurisée
J+27	Buffer / corrections / soutenance	Tous	—

5. Répartition des rôles

L'enseignant peut interroger chaque membre sur n'importe quelle partie : **chacun doit comprendre l'ensemble**. La répartition ci-dessous est une responsabilité de pilotage, pas

un cloisonnement.

Membre	Pilotage principal	Doit aussi savoir expliquer
A — Data & analyse	Acquisition, nettoyage, EDA, stratification, sensibilité	Architecture du modèle, choix du LMM
B — Modélisation	Extraction features, entraînement, évaluation, explicabilité	Provenance et biais du dataset
C — MLOps & livrables	Squelette repo, app Gradio, déploiement HF, rapport, PPT	Justification métier et limites

6. Métriques de succès

6.1 Performance modèle

Métrique	Cible générique (CIFAKE+ArtiFact)	Cible domaine (habitation)	Justification
ROC-AUC	> 0.90	> 0.75	Synthèse standard, robuste au déséquilibre
F1 (classe fraude)	> 0.85	> 0.70	Compromis precision/recall
Recall (classe fraude)	> 0.85	> 0.80	Métrique métier prioritaire
Latence inférence (1 image)	< 10 s sur HF Spaces (Streamlit)	—	Convient à un usage opérationnel

6.2 Livrables (consignes ISFA)

- Rapport PDF 10-15 pages (plan imposé en 7 sections).
- PPT synthétique 10-12 slides.
- Notebook Jupyter exécutable + repo GitHub public ou partagé.
- Application déployée fonctionnelle (Gradio sur HF Spaces).

7. Risques et mitigations

#	Risque	Probabilité	Impact	Mitigation
R1	Dataset spécifique habitation trop petit ou biaisé	Élevée	Élevé	Étage 1 sur dataset générique pour pré-train + acceptation explicite de la limite dans le rapport

#	Risque	Probabilité	Impact	Mitigation
R2	LLaVA / BLIP-2 trop lourd pour Colab Free	Moyenne	Moyen	Quantization 4-bit, batch size 1, fallback CLIP-seul si nécessaire
R3	HuggingFace Space tombe en panne le jour J	Faible	Élevé	Démo locale streamlit run 05_app/app.py en backup + capture vidéo de la démo
R4	Sur-apprentissage sur la signature SDXL (le modèle n'apprend que « SDXL vs photo »)	Élevée	Moyen	Évaluation cross-générateur (Midjourney, Flux) pour mesurer la généralisation
R5	Indisponibilité d'un membre (maladie, charge pro)	Moyenne	Moyen	Documentation systématique en cellules markdown, code commenté, aucune dépendance personne-machine locale critique
R6	Manque de temps pour la soutenance	Moyenne	Élevé	Buffer de 2 jours en S4, répétitions chronométrées en S4

8. Bibliographie de démarrage (à étoffer)

- Bird, J. J., & Lotfi, A. (2024). *CIFAKE : Image Classification and Explainable Identification of AI-Generated Synthetic Images*. IEEE Access.
- Rahman, M. A., et al. (2023). *ArtiFact : A Large-Scale Dataset with Artificial and Factual Images for Generalizable and Robust Synthetic Image Detection*. ICIP.
- Radford, A., et al. (2021). *Learning Transferable Visual Models From Natural Language Supervision* (CLIP). ICML.
- Liu, H., et al. (2023). *Visual Instruction Tuning* (LLaVA). NeurIPS.
- Li, J., et al. (2023). *BLIP-2 : Bootstrapping Language-Image Pre-training* (BLIP-2). ICML.
- ALFA — Agence pour la Lutte contre la Fraude à l'Assurance, rapports annuels.
- ACPR — recommandations sur l'usage de l'IA dans le secteur financier.

9. Point d'attention soutenance

Sur 20 points, **8 points sont alloués à la présentation orale** (dont la qualité des réponses aux questions). Conséquences pratiques :

- Construire le PPT autour d'**une seule histoire** : «voici le problème métier, voici notre approche, voici la démo, voici les limites assumées».
- La **démo live** est explicitement encouragée par la note de cadrage. Elle doit être courte (90 secondes max) et tester un cas légi